ENSAE PARIS

Projet de Data Storytelling

Analyse des catastrophes naturelles

Préparé par :

YASMINE ALUCH
KHAWLA ED-DAZAZI
RIME EL AMRANI JOUTEI

Professeurs :

M. EMMANUEL
PIETRIGA M. ARNAUD
PROUZEAU

Année scolaire : 2025-2026

Sommaire

Motivation du projet 3
Approche méthodologique 3
Description des visualisations 4
Carte choroplèthe : nombre d'événements par région 4
Série temporelle : évolution annuelle du nombre d'événements par région 4
Boîtes à moustaches : saisonnalité mensuelle des catastrophes par type de risque 5
Comparaison mensuelle interannuelle des catastrophes 6
Visualisation combinée : risque d'inondation à l'échelle régionale 7
Limites et portée critique des visualisations 8

1 . Motivation du projet

Notre projet de data storytelling porte sur l'analyse des catastrophes naturelles en France à partir de données ouvertes (notamment la base GASPAR).

L'objectif principal était de mieux comprendre l'exposition du territoire français aux différents périls naturels (inondations, sécheresse, mouvements de terrain, etc.) et de rendre ces informations accessibles de manière visuelle et intuitive.

Cette problématique s'inscrit dans un contexte marqué par le changement climatique, qui influence la fréquence et l'intensité de certains aléas naturels. Plusieurs travaux scientifiques montrent une augmentation des événements extrêmes, notamment des épisodes de sécheresse et d'inondation en Europe.

Ainsi, notre motivation est double :

- Permettre à un utilisateur non expert de comprendre rapidement les dynamiques spatiales et temporelles des catastrophes naturelles.
- Fournir des outils visuels permettant d'explorer des hypothèses, comme : Certaines régions sont-elles plus exposées que d'autres ? Observe-t-on une évolution dans le temps ? Existe-t-il un lien entre certains types d'aléas et des caractéristiques géographiques ?

2 . Approche méthodologique

Nous avons adopté une approche basée sur la visualisation interactive et exploratoire.

Les données ont été :

- nettoyées et harmonisées (formats, noms des variables, filtres temporels),
- enrichies par des données géographiques (communes, régions),
- structurées pour permettre des analyses par type de risque,
- zone géographique et période temporelle.

Nos visualisations ont été conçues avec les objectifs suivants :

- faciliter la lecture rapide des tendances,
- permettre une exploration multi-échelle (France $\rightarrow$ régions $\rightarrow$ communes),
- croiser les dimensions spatiales et temporelles.

3 . Description des visualisations

3.1 Carte choroplèthe : nombre d'événements par région

Nous visons via cette visualisation représenter **la distribution spatiale des catastrophes naturelles sur le territoire français**, en agrégeant le nombre d'événements par région. Le choix d'une carte choroplèthe permet de transformer une information quantitative en une information visuelle immédiatement lisible.

À travers cette visualisation, nous cherchons d'abord à identifier les régions les plus exposées aux catastrophes naturelles. Les régions apparaissant avec les couleurs les plus foncées correspondent à celles où le nombre d'événements recensés est le plus élevé, tandis que les régions plus claires sont relativement moins touchées. Cette première lecture permet de repérer rapidement les territoires les plus concernés et de dégager des zones de vulnérabilité potentielle.

La carte permet également de visualiser les contrastes territoriaux. En effet, les catastrophes naturelles ne se répartissent pas de manière homogène sur l'ensemble du territoire français. Certaines régions apparaissent nettement plus exposées que d'autres, ce qui peut s'expliquer par des différences climatiques, topographiques ou hydrologiques. La visualisation rend donc possibles des comparaisons entre les différentes parties du territoire. Les limites propres à cette visualisation sont discutées dans la section dédiée en fin de rapport.

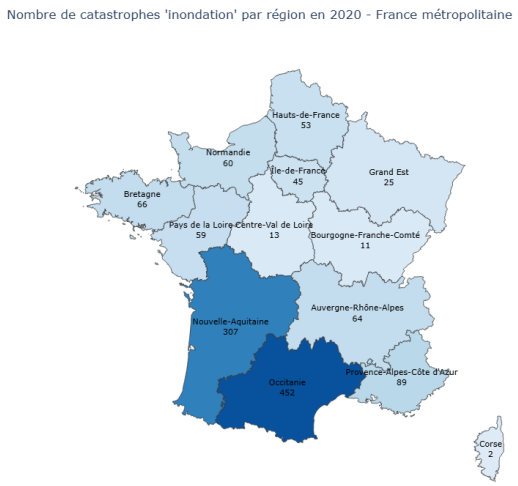

Figure 1: Nombre d'inondation par région en 2020 en France métropolitaine

Sur cette carte, on observe la répartition spatiale des événements d'inondation en France métropolitaine pour l'année 2020. Elle met en évidence de fortes disparités régionales, avec une concentration particulièrement marquée dans le sud-ouest, notamment en Occitanie et en Nouvelle-Aquitaine, qui apparaissent comme les régions les plus touchées. À l'inverse, certaines régions du centre et de l'est présentent des niveaux nettement plus faibles, traduisant une exposition moindre pour cette année donnée. Cette visualisation offre ainsi une lecture immédiate des zones les plus exposées aux inondations en 2020.

3.2 Série temporelle : évolution annuelle du nombre d'événements par région

Cette visualisation consiste en une série temporelle représentant le nombre de catastrophes naturelles observées chaque année dans une région donnée. Elle permet d'introduire une dimension dynamique dans l'analyse, en complément des cartes statiques, en mettant en évidence l'évolution du phénomène dans le temps.

L'objectif principal est d'analyser la trajectoire temporelle du nombre d'événements. En observant la courbe, il est possible d'identifier une tendance globale, qu'elle soit à la hausse, à la baisse ou relativement stable. Cette tendance donne une première indication sur l'évolution de l'exposition de la région aux risques naturels au fil des années.

La série temporelle permet également de repérer des années atypiques, caractérisées par des pics ou des chutes marquées du nombre d'événements. Ces fluctuations peuvent correspondre à des épisodes climatiques exceptionnels ou à des événements extrêmes. L'identification de ces années particulières est essentielle, car elles peuvent fortement influencer la perception du risque et nécessitent souvent une analyse plus approfondie.

Par ailleurs, cette visualisation ouvre la voie à une réflexion sur un éventuel lien avec le changement climatique. Une augmentation progressive du nombre d'événements, ou une intensification des pics, peut être cohérente avec les observations scientifiques relatives à l'évolution des aléas climatiques. Néanmoins, il est important de souligner que la série temporelle seule ne permet pas d'établir un lien de causalité direct, mais constitue un outil d'exploration permettant de formuler des hypothèses. Les limites propres à cette visualisation sont discutées dans la section dédiée en fin de rapport.

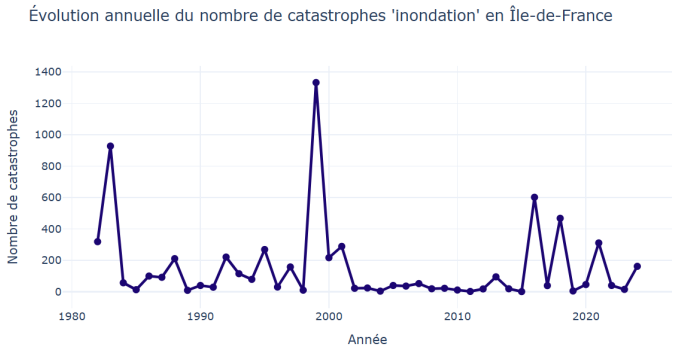

Figure 2: Evolution annuelle des innondations en Île de France

En prenant l'exemple des innondations en Île de France, on observe une forte variabilité interannuelle, caractérisée par la présence de pics marqués, notamment à la fin des années 1990 et au milieu des années 2010. Ces années atypiques traduisent la survenue d'épisodes exceptionnels, qui contrastent avec des périodes plus calmes.

3.3 Boîtes à moustaches : saisonnalité mensuelle des catastrophes par type de risque

Nous visons via cette visualisation représenter **la distribution mensuelle des catastrophes naturelles par type de risque**, en agrégeant le nombre d'événements recensés chaque mois sur l'ensemble des années disponibles. Le choix des boîtes à moustaches permet de résumer, pour chaque mois calendaire, non seulement le niveau typique du nombre d'événements, mais aussi leur variabilité d'une année sur l'autre.

À travers cette visualisation, nous cherchons d'abord à identifier la signature saisonnière propre à chaque aléa. Chaque panneau du graphique représente un risque différent, et à l'intérieur d'un panneau, douze boîtes à moustaches sont juxtaposées, une pour chaque mois de l'année. La médiane, les quartiles et l'étendue inter-quartile permettent de lire immédiatement les mois où le phénomène se concentre, ainsi que l'amplitude des écarts entre les années.

La représentation met également en évidence la variabilité interannuelle du phénomène. Une boîte très étendue signifie que, pour ce mois précis, le nombre d'événements varie fortement d'une année à l'autre,

ce qui traduit une irrégularité du phénomène. À l'inverse, une boîte resserrée indique une occurrence stable et prévisible. Pour préserver la lisibilité des tendances centrales, les valeurs extrêmes ont été volontairement masquées afin d'éviter que quelques années exceptionnelles n'écrasent l'échelle verticale. Les limites propres à cette visualisation sont discutées dans la section dédiée en fin de rapport.

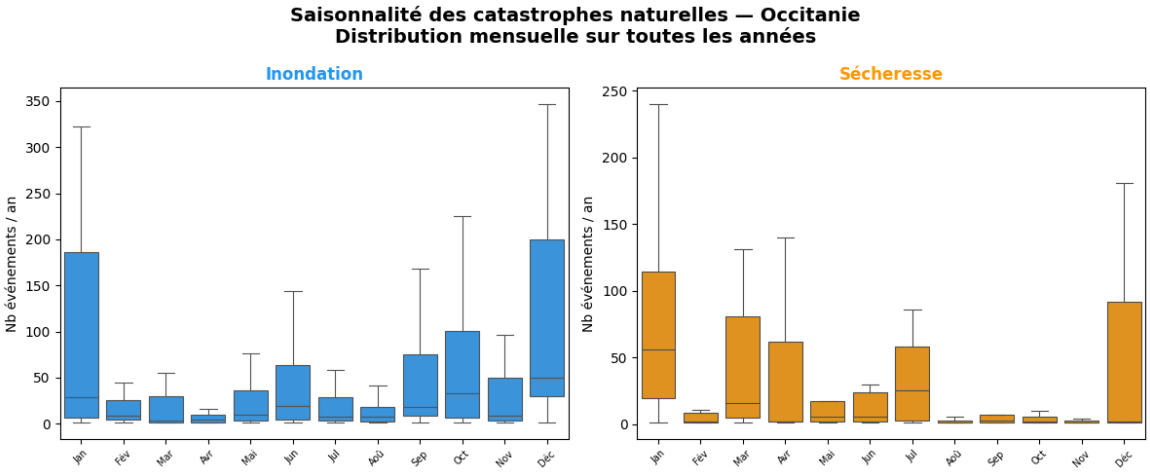

Figure 3: Saisonnalité mensuelle des catastrophes naturelles en Occitanie pour les risques d'inondation et de sécheresse

Sur cet exemple appliqué à la région Occitanie pour les risques d'inondation et de sécheresse, les deux aléas présentent des profils clairement distincts. L'inondation affiche des boîtes nettement plus hautes en janvier, en décembre, ainsi qu'en septembre et octobre, ce qui correspond bien au régime méditerranéen caractéristique de cette région, avec des épisodes pluvieux intenses concentrés en fin d'année. La sécheresse, en revanche, présente des médianes plus élevées en janvier, en mars et en juillet, avec une dispersion marquée sur une large partie de l'année, traduisant à la fois l'étalement temporel des épisodes physiques et les délais administratifs de reconnaissance.

3.4 Comparaison mensuelle interannuelle des catastrophes

Cette visualisation consiste en une superposition de courbes mensuelles, chacune correspondant à une année sélectionnée, pour un ou plusieurs types de risques donnés dans une région choisie. Elle permet de compléter la boîte à moustaches en descendant au niveau de l'année et en rendant visible, sur un même graphique, le profil saisonnier de plusieurs années consécutives.

L'objectif principal est de comparer la dynamique intra-annuelle des catastrophes d'une année à l'autre. En reliant les douze points mensuels de chaque année par une courbe distincte, la visualisation met immédiatement en évidence les années qui s'écartent du comportement habituel, ainsi que les éventuels décalages de phase, c'est-à-dire les cas où un pic d'activité se déplace d'un mois à l'autre selon les années.

La représentation permet également de repérer les années atypiques. Un pic mensuel exceptionnellement élevé par rapport aux autres années sélectionnées peut traduire la survenue d'un épisode météorologique marquant et invite à approfondir l'analyse sur cette période. Un traitement explicite des mois sans événement a été intégré afin que les zéros apparaissent bien sur la courbe et ne créent pas d'interruptions visuelles trompeuses. Par ailleurs, la fonction filtre automatiquement les risques pour lesquels aucune donnée n'est disponible sur la période demandée, de sorte que seuls les aléas effectivement observés apparaissent dans la figure finale. Les limites propres à cette visualisation sont discutées dans la section dédiée en fin de rapport. Sur cet exemple appliqué à la région Bretagne pour les années 2003 à 2005, seul le risque d'inondation a été retenu, les autres aléas demandés n'ayant pas fait l'objet de reconnaissances régionales sur cette période. On observe un profil saisonnier inhabituel, les trois années restant globalement calmes de septembre à décembre tandis que la période estivale concentre l'activité. L'année 2005 se distingue nettement avec un

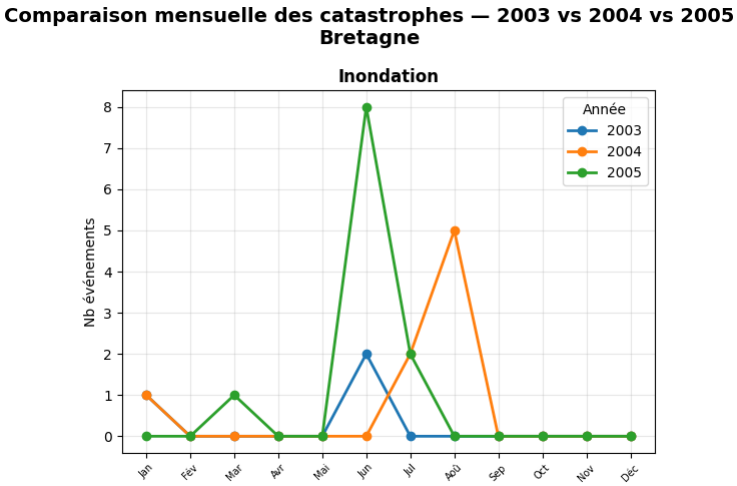

Figure 4: Évolution mensuelle du nombre d'inondations en Bretagne pour les années 2003, 2004 et 2005

pic de huit inondations au mois de juin, tandis que l'année 2004 présente un profil décalé avec son propre pic en août. L'année 2003 reste très modérée tout au long de l'année. Cette juxtaposition illustre la capacité de la visualisation à identifier à la fois des années atypiques et des décalages de phase d'une année à l'autre.

3.5 Visualisation combinée : risque d'inondation à l'échelle régionale

Cette visualisation se concentre spécifiquement sur le risque d'inondation. Elle combine deux représentations complémentaires : une carte localisée des cours d'eau traversant la région étudiée et une série temporelle montrant l'évolution annuelle du nombre d'événements d'inondation dans cette même région.

L'objectif de cette approche est de croiser les dimensions spatiale et temporelle afin de mieux comprendre les déterminants du risque d'inondation. La carte permet d'identifier les caractéristiques géographiques locales, notamment la présence et la densité du réseau hydrographique. La série temporelle, quant à elle, permet d'analyser la dynamique du phénomène dans le temps.

L'intérêt principal de cette visualisation réside dans sa capacité à suggérer des liens entre la géographie locale et la fréquence des inondations. Par exemple, une région présentant un réseau hydrographique dense et montrant une fréquence élevée d'événements d'inondation peut illustrer l'influence de ces facteurs physiques sur le risque. À l'inverse, une faible occurrence malgré la présence de cours d'eau peut inviter à explorer d'autres variables explicatives, telles que les aménagements hydrauliques ou les politiques de prévention. Les limites propres à cette visualisation sont discutées dans la section dédiée en fin de rapport.

La figure ci- dessous illustre le cas de l'Île-de-France en combinant une carte du réseau hydrographique et l'évolution annuelle des inondations. On observe une forte densité de cours d'eau, tandis que la série temporelle met en évidence une variabilité importante avec des pics marqués, notamment en 1999. Cela souligne le caractère irrégulier du risque d'inondation, lié à des événements climatiques ponctuels, malgré une exposition géographique relativement stable.

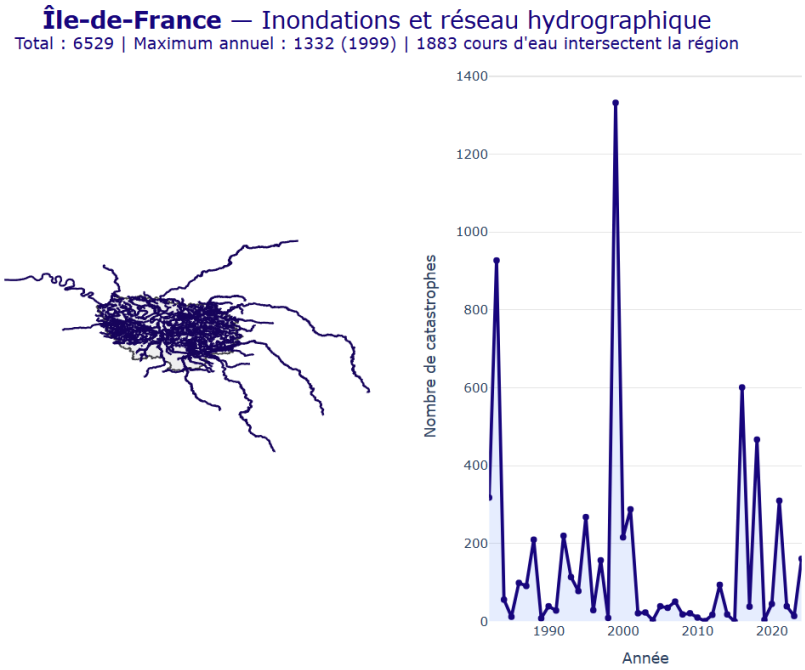

Figure 5: Risque d'inondation en Île-de-France : réseau hydrographique et évolution annuelle

4 . Limites et portée critique des visualisations

Cette section revient de manière synthétique sur les limites méthodologiques propres à chacune des visualisations présentées précédemment. Loin de constituer des faiblesses, ces limites traduisent autant de choix assumés dans la conception de notre analyse et délimitent clairement le périmètre interprétatif de chaque représentation. Les expliciter permet de rendre compte de la rigueur de la démarche, de prévenir toute sur-interprétation des résultats, et d'ouvrir la voie à des approfondissements futurs, notamment par la mobilisation de sources complémentaires.

4.1 Carte choroplèthe par région

Cette visualisation présente certaines limites qui traduisent des choix de cadrage assumés dès la conception. Elle repose sur des valeurs absolues plutôt que sur des taux d'incidence rapportés à la population ou à la superficie, ce qui signifie que les régions les plus vastes ou les plus peuplées peuvent mécaniquement enregistrer davantage d'événements. Ce choix est cohérent avec l'objectif exploratoire de cette première représentation, qui vise à localiser les zones à forte fréquence d'événements avant toute normalisation, mais il mérite d'être explicité pour éviter toute sur-interprétation.

De plus, la carte n'intègre pas directement l'intensité des catastrophes, ni leur impact humain ou économique. Cette limite est inhérente à la structure de la base GASPAR, qui recense des reconnaissances administratives sans graduation de sévérité. Loin d'invalider la démarche, elle en délimite clairement le périmètre : il s'agit ici de cartographier la fréquence du phénomène et non sa gravité, cette dernière dimension relevant de bases complémentaires que des travaux ultérieurs pourraient mobiliser. La carte remplit ainsi pleinement son rôle introductif en mettant en évidence les régions sur lesquelles concentrer l'attention dans la suite de l'analyse.

4.2 Série temporelle annuelle

La série temporelle présente plusieurs limites qui reflètent autant de précautions méthodologiques intégrées à notre réflexion. En premier lieu, les données peuvent être influencées par des changements dans les méthodes de recensement ou de déclaration des événements au cours du temps, notamment depuis la mise en place progressive de la base GASPAR et l'évolution des procédures administratives de reconnaissance. Une hausse apparente du nombre d'événements peut ainsi refléter en partie une amélioration de la couverture statistique plutôt qu'une augmentation réelle du phénomène.

En second lieu, le nombre d'événements ne reflète pas nécessairement leur intensité ni leurs impacts. Cette limite, commune à l'ensemble de nos représentations, est inhérente à la nature administrative de la base utilisée et délimite clairement le périmètre interprétatif de la visualisation : nous décrivons la fréquence du phénomène, non sa sévérité. Elle justifie également notre choix de combiner plusieurs représentations complémentaires plutôt que de nous appuyer sur une seule courbe globale, afin de multiplier les angles de lecture et de construire une compréhension plus robuste du phénomène.

4.3 Boîtes à moustaches de saisonnalité

Comme toute représentation synthétique, cette visualisation repose sur plusieurs choix méthodologiques qu'il importe d'expliciter. En premier lieu, les dates figurant dans la base GASPAR correspondent aux reconnaissances officielles de catastrophe naturelle et non au moment exact de l'événement physique, ce qui introduit un décalage administratif parfois significatif, particulièrement marqué pour la sécheresse dont la reconnaissance peut intervenir plusieurs mois après le début de l'épisode. Cette distinction est essentielle pour interpréter correctement les médianes mensuelles et a orienté notre choix de présenter plusieurs visualisations complémentaires plutôt qu'une lecture unique.

En second lieu, le masquage volontaire des valeurs extrêmes constitue un compromis assumé : il améliore considérablement la lisibilité des tendances centrales mais peut atténuer visuellement l'impact d'années exceptionnelles. Ce choix est cohérent avec la finalité saisonnière de la visualisation, qui vise à caractériser le comportement typique d'un risque plutôt qu'à quantifier les épisodes hors norme.

Enfin, l'agrégation de toutes les années dans une même distribution masque nécessairement l'évolution temporelle du phénomène, ce qui empêche de détecter une éventuelle tendance de fond ou l'effet du changement climatique. Cette limite a été anticipée dès la conception et justifie précisément l'articulation des différentes visualisations du rapport, chacune couvrant une dimension analytique distincte.

4.4 Comparaison mensuelle interannuelle

Cette visualisation présente des limites qui reflètent autant de choix méthodologiques assumés plutôt que des insuffisances. Le nombre d'années superposées doit rester modéré, en pratique trois à cinq, afin de préserver la lisibilité des courbes et d'éviter une saturation visuelle. Cette contrainte impose une sélection ciblée des années d'intérêt plutôt qu'une comparaison exhaustive, et suppose donc une connaissance préalable des périodes susceptibles de révéler des dynamiques pertinentes. Notre exemple sur la Bretagne pour les années 2003 à 2005 a été précisément conçu pour illustrer la capacité de la visualisation à détecter des années atypiques, sans prétendre à une analyse exhaustive du risque d'inondation dans cette région.

Par ailleurs, la visualisation représente un nombre d'événements et non leur intensité, ce qui implique qu'une année comportant peu d'événements mais très sévères peut apparaître visuellement moins marquée qu'une année accumulant de nombreux épisodes mineurs. Loin d'invalider la démarche, cette limite en délimite clairement le périmètre et invite à compléter l'analyse par des sources tierces dans des travaux ultérieurs.

Enfin, le filtrage automatique des risques pour lesquels aucune donnée n'est disponible sur la période demandée, bien qu'il améliore la robustesse de la fonction, peut masquer des absences significatives. Un risque non représenté ne signifie pas nécessairement qu'il n'existe pas dans la région, mais simplement qu'il n'a pas été recensé administrativement sur les années choisies. Ce point constitue en soi une information analytique qu'il peut être pertinent de mentionner explicitement lors de la lecture du graphique.

4.5 Visualisation combinée à l'échelle régionale

Cette dernière visualisation présente des limites qui traduisent la complexité intrinsèque du phénomène étudié plutôt qu'une insuffisance de la représentation. La présence de cours d'eau ne suffit pas à expliquer à elle seule le risque d'inondation : d'autres facteurs interviennent, tels que l'intensité des précipitations, l'occupation du sol ou les infrastructures de protection. La visualisation n'a donc pas vocation à fournir une explication causale complète, mais à rendre visibles les corrélations spatiales les plus évidentes afin d'orienter les hypothèses vers les régions où ces facteurs mériteraient d'être explorés plus finement.

De plus, le nombre d'événements ne reflète pas nécessairement leur gravité, limite inhérente à la base GASPAR. Cette contrainte, commune à l'ensemble de nos visualisations, a été prise en compte dans la manière dont elles s'articulent : en croisant plusieurs dimensions (spatiale, temporelle, saisonnière et géographique), nous compensons partiellement cette limite en enrichissant la lecture globale du risque.

Synthèse : Les limites identifiées au fil de cette section dessinent en creux les choix méthodologiques qui structurent notre démarche : un ancrage sur la base GASPAR pour sa couverture nationale exhaustive, un traitement de la fréquence plutôt que de la sévérité compte tenu des données disponibles, et une stratégie de visualisations multiples et complémentaires pour compenser les angles morts de chaque représentation prise isolément. Des approfondissements futurs pourront utilement mobiliser des bases d'impact humain ou économique, affiner les échelles géographiques jusqu'au niveau communal, et intégrer des variables explicatives supplémentaires telles que la pluviométrie ou l'occupation du sol, afin de passer d'une cartographie descriptive à une modélisation explicative du risque.